

Razonamiento latente adaptativo: *halting* probabilístico tipo PonderNet sobre cadenas de pensamiento implícitas

Ana Paula Tissera, Valentino Arbelaiz Alberti, Franco Amato de Lusarreta, Naomi Couriel, Juan Cruz Giner Pulero

Introducción

Los modelos de *chain-of-thought latente* (Cocnut, CODI, SIM-CoT) reemplazan el razonamiento en texto por vectores continuos, a un costo mucho menor que el de CoT explícito. Pero fijan de antemano el número de pasos latentes K y el número de vectores por paso c , aplicándolos por igual a toda entrada: un problema de dos operaciones consume el mismo presupuesto que uno de seis. Este trabajo hace ese presupuesto **adaptativo por instancia**.


Objetivos

Hacer el presupuesto de razonamiento **adaptativo por instancia**, en tres frentes:

- Mostrar que el presupuesto óptimo **depende de la instancia** y ver si es predecible *upfront* desde la consigna.
- Hacer adaptativo el número de **pasos** K con *halting* estilo PonderNet, y caracterizar la frontera entre accuracy y cómputo que un K fijo no captura (**aporte principal**).
- Explorar el otro eje del presupuesto: los **vectores por paso** c .

¿Cuánto razonamiento?

Ejecutamos CODI variando $k \in \{1, \dots, 8\}$ sobre $n=7473$ ejemplos y medimos k^* (el menor k que alcanza la mejor accuracy para cada instancia).



La accuracy sube 23 puntos hasta $k \approx 5-6$ y luego se estabiliza. Pero el óptimo k^* está muy **desbalanceado** (66 % de las instancias resuelven con $k^*=1$): **existe margen para adaptar el presupuesto por instancia**.


Un clasificador entrenado para predecir k^* a partir de *embeddings* congelados (MiniLM) no supera a la clase mayoritaria (RF: 0.661; LR: 0.210). La dificultad **no puede leerse upfront**: hay que decidir *durante* el razonamiento.

Referencias

- Hao et al. *Training Large Language Models to Reason in a Continuous Latent Space* (Cocnut), 2024.
- Shen et al. *CODI: Compressing Chain-of-Thought into Continuous Space via Self-Distillation*, 2025.
- Wei et al. *SIM-CoT: Supervised Implicit Chain-of-Thought*, 2025.
- Banino, Balaguer y Blundell. *PonderNet: Learning to Ponder*, 2021.

Método: *halting* adaptativo

El modelo realimenta su último estado oculto como próxima entrada (z_k , "pensamientos continuos"). Una única *halting head* lineal decide, en cada paso, si el razonamiento acumulado ya es suficiente para responder:



En cada paso, el modelo predice una probabilidad de parada condicional y se decodifica una respuesta candidata para cada prefijo $k = 1, \dots, K$, formando la distribución de parada de PonderNet (con frontera absorbente en K):

$$\lambda_k = \sigma(\text{halt_head}(h_k))$$

$$p_k = \left(\prod_{j < k} (1 - \lambda_j) \right) \lambda_k.$$

La función objetivo combina términos de los tres métodos: PonderNet (pérdida esperada + regularización KL), SIM-CoT (supervisión por paso) y CODI (losses de destilación):

$$\mathcal{L} = \underbrace{\sum_k p_k \mathcal{L}_{\text{ans}}^{(k)}}_{\mathcal{L}_{\text{ponder}}} + \beta \mathcal{L}_{\text{step}} + \gamma \text{KL}_{\text{geom}} + \mathcal{L}_{\text{distill}} + \mathcal{L}_{\text{ref}}.$$

- El peso γ **controla el cómputo**: regula la influencia del prior geométrico y, con ella, cuánto se acorta la cadena de razonamiento.
- En inferencia, el razonamiento se detiene cuando la masa acumulada de parada supera un umbral (por defecto 0.5); K_{max} fija el límite superior.

Prior geométrico por instancia

En lugar de usar un prior geométrico global, hacemos que el presupuesto esperado dependa de cada instancia. Para ello, lo parametrizamos como una función afín del número de operaciones n_i :

$$\text{geom_mean}_i = \text{clamp}(\alpha n_i + \beta, \beta, K_{\text{max}}).$$




Figura. Distribución de n_i en GSM8k-Aug ($\mu=1.59$).

Configuración experimental

- Datos:** GSM8k-Aug (razonamiento paso a paso, Deng et al.; $\sim 385k$ ejemplos de *train*). El tamaño de entrenamiento **varía según el experimento** (desde el *train* completo hasta subconjuntos chicos); los modelos de la banda de resultados usan 100k ejemplos.
- Modelo:** GPT-2 (124M), inicializado desde el checkpoint CODI de SIM-CoT (*warm-start*). Afinamos la **red completa** (no solo adaptadores) junto con la *halting head*, con un tope de $K_{\text{max}}=12$ pasos latentes.
- Evaluación:** accuracy *greedy*, una sola pasada y *batch_size*=1, sobre el **test de 1319 ejemplos** nunca visto en entrenamiento. La epoch y el threshold de halt se eligieron en un set de validación aparte (500 ejemplos).
- Baseline** (K fijo = 6): **39.50 %**.

El otro eje: vectores por paso (c)

Cada paso se construye con hasta M sub-vectores; un MLP destila la pérdida de reconstrucción del decoder ($\hat{\mathcal{L}} = \text{MLP}(h)$) y sobrevive a inferencia: el paso termina cuando $\hat{\mathcal{L}}$ converge.

Init $\times$ granularidad	$c=1$	$c=2$	$c=3$	$\Delta_{2 \rightarrow 3}$
warm + atómica	27.5	39.4	39.9	+0.5
warm + gruesa	25.5	36.6	40.3	+3.7
cold + gruesa	5.3	5.5	5.5	n/d


Con pasos atómicos (una operación por paso), la accuracy **satura en $c=2$** : la parada adaptativa no mejora sobre la aleatoria. Con pasos gruesos (densidad variable), la mejora reaparece (adaptativo $>$ aleatorio por 2.7σ), aunque es pequeña.

La variabilidad parece estar en el número de pasos, más que en la complejidad de cada paso.

Conclusiones

- El *halting* aprendido **igual a al baseline de K fijo** (≈ 39.5 % en test) recortando **cerca de la mitad de los pasos latentes** (3.01 vs. 6).
- Fuerte seguimiento de la dificultad: **Spearman** +0.626 entre operaciones y pasos usados (M2, test).
- Dos resultados negativos informativos: la dificultad no es legible *upfront*; el eje c no tiene margen en GSM8k-Aug.
- A futuro: comparación justa entrenando GPT-2 **desde cero** (sin *warm-start*, con el train completo y 40 épocas; en curso), otros backbones y tareas.


Resultado principal: *halting* adaptativo en test ($n=1319$): la mitad del cómputo, sin perder accuracy



Umbral	M0 $\alpha 1.0, \gamma 0.5$	M1 $\alpha 1.0, \gamma 1.0$	M2 $\alpha 0.6, \gamma 1.0$
0.3	39.1 @ 3.34	39.1 @ 2.60	38.4 @ 2.10
0.4	39.6 @ 3.86	39.4 @ 3.16	39.4 @ 2.52
0.5	40.0 @ 4.46	39.4 @ 3.73	39.9 @ 3.01
0.8	40.2 @ 6.97	39.7 @ 6.39	40.0 @ 4.98

Accuracy (%) @ pasos latentes promedio. M0/M1/M2 son el mismo modelo adaptativo con distinta intensidad γ del regularizador y pendiente α del prior; baseline de K fijo: 39.5 @ 6.0.

Todas las configuraciones alcanzan una accuracy similar ($\sim 39-40$ %). M2 con umbral 0.5 logra 39.9 % usando solo 3.01 pasos: **la mitad** del cómputo del baseline de K fijo.



Pasos usados vs. dificultad (M2, umbral 0.5, test): la masa sigue la diagonal. **Spearman** = +0.626: el cómputo se asigna por dificultad, no de forma uniforme.