


Razonamiento latente adaptativo: *halting* probabilístico tipo PonderNet sobre cadenas de pensamiento implícitas

Ana Paula Tissera, Valentino Arbelaiz Alberti, Franco Amato de Lusarreta, Naomi Couriel, Juan Cruz Giner Pulero

El problema

El *chain-of-thought* latente (Coconut, CODI, SIM-CoT) razona con vectores continuos en vez de texto, reduciendo el costo del CoT explícito, pero **asigna el mismo presupuesto a todas las entradas**. Proponemos **adaptarlo por instancia** en dos ejes: pasos latentes K y vectores por paso c .


1 · ¿Dificultad predecible?



CODI forzando k ($n=7473$): la accuracy sube 23 puntos hasta $k \approx 5-6$ y satura. Pero el óptimo k^* por instancia está muy **desbalanceado** (66 % resuelve con $k^*=1$).


Un clasificador entrenado para predecir k^* a partir de *embeddings* congelados (MiniLM) no supera a la clase mayoritaria (RF: 0.661; LR: 0.210). La dificultad **no puede leerse *upfront***.

Accuracy por dificultad



El modelo adaptativo empata al baseline de K fijo **en cada nivel de dificultad**, no solo en el agregado.

Método: *halting* adaptativo



Probabilidad de parada condicional por paso, y distribución de parada de PonderNet (frontera absorbente en K):

$$\lambda_k = \sigma(\text{halt_head}(h_k))$$

$$p_k = (\prod_{j < k} (1 - \lambda_j)) \lambda_k.$$

Función objetivo:

$$\mathcal{L} = \sum_k p_k \mathcal{L}_{\text{ans}}^{(k)} + \gamma \text{KL}_{\text{geom}} + \beta \mathcal{L}_{\text{step}} + \mathcal{L}_{\text{distill}} + \mathcal{L}_{\text{ref}}$$

■ PonderNet ■ SIM-CoT ■ CODI

- γ **controla el cómputo**: regula el prior geométrico y, con él, cuánto se acorta la cadena.
- En inferencia se detiene cuando $\sum_{j \leq k} p_j \geq \tau$ (0.5 por defecto) o al alcanzar K_{max} .

Prior geométrico por instancia

Parametrizamos el presupuesto esperado de cada instancia como una función afín de su número de operaciones n_i :

$$\text{geom_mean}_i = \text{clamp}(\alpha n_i + \beta, \beta, K_{\text{max}}).$$




Figura. Distribución de n_i en GSM8k-Aug ($\mu=1.59$).

Configuración experimental

Datos GSM8k-Aug (~385k); *train* variable según el experimento (100k en los resultados); **test: 1319**

Modelo GPT-2 124M, *warm-start* del checkpoint CODI de SIM-CoT


Ajuste red completa + halting head; tope $K_{\text{max}}=12$

Eval *greedy*, una pasada, bs=1

Selección epoch y umbral en validación aparte (500 ej.)

Baseline (K fijo = 6): 39.50 %.

3 · El otro eje: vectores por paso (c)



Con pasos atómicos la accuracy **satura** en $c=2$; con gruesos reaparece una mejora chica (2.7σ sobre aleatoria).


La variabilidad parece estar en la cantidad de pasos, no en la complejidad de cada uno.

Conclusiones

- El *halting* adaptativo **mantiene la accuracy del baseline K fijo** (≈ 39.5 %) usando **cerca de la mitad de los pasos** (3.01 vs. 6).
- La dificultad no es legible *upfront*; el eje c no tiene margen en GSM8k-Aug.


A futuro: entrenar GPT-2 **desde cero** (sin *warm-start*, train completo, 40 épocas), otros backbones y tareas.

2 · Resultado principal: *halting* adaptativo en test ($n=1319$): la mitad del cómputo, sin perder accuracy



Umbral	M0 $\alpha 1.0, \gamma 0.5$	M1 $\alpha 1.0, \gamma 1.0$	M2 $\alpha 0.6, \gamma 1.0$
0.3	39.1 @ 3.34	39.1 @ 2.60	38.4 @ 2.10
0.4	39.6 @ 3.86	39.4 @ 3.16	39.4 @ 2.52
0.5	40.0 @ 4.46	39.4 @ 3.73	39.9 @ 3.01
0.8	40.2 @ 6.97	39.7 @ 6.39	40.0 @ 4.98

Accuracy (%) @ pasos latentes promedio. M0/M1/M2 son el mismo modelo adaptativo con distinta intensidad γ del regularizador y pendiente α del prior; baseline de K fijo: 39.5 @ 6.0.



Pasos usados vs. dificultad (M2, umbral 0.5, test): la masa sigue la diagonal. **Spearman** = +0.626: el cómputo se asigna por dificultad.