


Razonamiento latente adaptativo: *halting* probabilístico tipo PonderNet sobre cadenas de pensamiento implícitas

Ana Paula Tissera, Valentino Arbelaiz Alberti, Franco Amato de Lusarreta, Naomi Couriel, Juan Cruz Giner Pulero

El problema

El *chain-of-thought latente* (Coconut, CODI, SIM-CoT) razona con vectores continuos en vez de texto, por un costo mucho menor que el CoT explícito. Pero fija el presupuesto de antemano y **lo aplica por igual a toda entrada**. Lo hacemos **adaptativo por instancia**, en dos ejes: los pasos latentes K y los vectores por paso c .

1 · ¿Dificultad predecible?




CODI forzando k ($n=7473$): la accuracy sube 23 puntos hasta $k \approx 5-6$ y satura. Pero el óptimo k^* por instancia está muy **desbalanceado** (66 % resuelve con $k^*=1$): **hay margen para adaptar el presupuesto**.

Un clasificador entrenado para predecir k^* a partir de *embeddings* congelados (MiniLM) no supera a la clase mayoritaria (RF: 0.661; LR: 0.210). La dificultad **no puede leerse upfront**: hay que decidir *durante* el razonamiento.

Referencias

- [1] Hao et al. *Training Large Language Models to Reason in a Continuous Latent Space* (Coconut), 2024.
- [2] Shen et al. *CODI: Compressing Chain-of-Thought into Continuous Space via Self-Distillation*, 2025.
- [3] Wei et al. *SIM-CoT: Supervised Implicit Chain-of-Thought*, 2025.
- [4] Banino, Balaguer y Blundell. *PonderNet: Learning to Ponder*, 2021.

Método: *halting* adaptativo



Probabilidad de parada condicional por paso, y distribución de parada de PonderNet (frontera absorbente en K):

$$\lambda_k = \sigma(\text{halt_head}(h_k))$$

$$p_k = \left(\prod_{j < k} (1 - \lambda_j) \right) \lambda_k.$$

La función objetivo **combina términos de los tres métodos**:

$$\mathcal{L} = \sum_k p_k \mathcal{L}_{\text{ans}}^{(k)} + \gamma \text{KL}_{\text{geom}} + \beta \mathcal{L}_{\text{step}} + \mathcal{L}_{\text{distill}} + \mathcal{L}_{\text{reg}}.$$

■ PonderNet ■ SIM-CoT ■ CODI

- γ **controla el cómputo**: regula el prior geométrico y, con él, cuánto se acorta la cadena.
- En inferencia se detiene cuando la masa acumulada de parada supera un umbral (por defecto 0.5); K_{max} es el tope.

Prior geométrico por instancia

En lugar de usar un prior geométrico global, hacemos que el presupuesto esperado dependa de cada instancia. Para ello, lo parametrizamos como una función afín del número de operaciones n_i :

$$\text{geom_mean}_i = \text{clamp}(\alpha n_i + \beta, \beta, K_{\text{max}}).$$




Figura. Distribución de n_i en GSM8k-Aug ($\mu=1.59$).

Configuración experimental

Datos GSM8k-Aug (Deng et al.); $\sim 385k$ ejemplos de *train*. El tamaño de entrenamiento varía según el experimento: los modelos de la banda de resultados usan 100k de *train*, *test* de 1319

Modelo GPT-2 124M, *warm-start* del checkpoint CODI de SIM-CoT

Ajuste red completa + halting head; tope $K_{\text{max}}=12$

Eval *greedy*, una pasada, *batch_size*=1

Selección epoch y umbral en validación aparte (500 ej.)

Baseline (K fijo = 6): 39.50 %.

3 · El otro eje: vectores por paso (c)

Cada paso usa hasta M sub-vectores; un MLP destila la pérdida de reconstrucción del decoder ($\hat{\mathcal{L}} = \text{MLP}(h)$) y el paso termina cuando $\hat{\mathcal{L}}$ converge.

Init $\times$ granularidad	$c=1$	$c=2$	$c=3$	$\Delta_{2 \rightarrow 3}$
warm + atómica	27.5	39.4	39.9	+0.5
warm + gruesa	25.5	36.6	40.3	+3.7
cold + gruesa	5.3	5.5	5.5	n/d


Con pasos atómicos la accuracy **satura** en $c=2$. Con pasos gruesos la mejora reaparece (2.7σ sobre parada aleatoria), pero es chica.

La variabilidad parece estar en # pasos, más que en la complejidad de cada uno.

Conclusiones


- El *halting* aprendido **igual a al baseline de K fijo** (≈ 39.5 % en test) recortando **cerca de la mitad de los pasos latentes** (3.01 vs. 6).
- Dos resultados negativos informativos: la dificultad no es legible *upfront*; el eje c no tiene margen en GSM8k-Aug.
- A futuro: comparación justa entrenando GPT-2 **desde cero** (sin *warm-start*, train completo, 40 épocas), otros backbones y tareas.

2 · Resultado principal: *halting* adaptativo en test ($n=1319$): la mitad del cómputo, sin perder accuracy



Umbral	M0	M1	M2
	$\alpha 1.0, \gamma .05$	$\alpha 1.0, \gamma .10$	$\alpha 0.6, \gamma .10$
0.3	39.1 @ 3.34	39.1 @ 2.60	38.4 @ 2.10
0.4	39.6 @ 3.86	39.4 @ 3.16	39.4 @ 2.52
0.5	40.0 @ 4.46	39.4 @ 3.73	39.9 @ 3.01
0.8	40.2 @ 6.97	39.7 @ 6.39	40.0 @ 4.98

Accuracy (%) @ pasos latentes promedio. M0/M1/M2 son el mismo modelo adaptativo con distinta intensidad γ del regularizador y pendiente α del prior; baseline de K fijo: 39.5 @ 6.0.



Pasos usados vs. dificultad (M2, umbral 0.5, test): la masa sigue la diagonal. **Spearman** = +0.626: el cómputo se asigna por dificultad, no de forma uniforme.